

AI Proxy Gateway - Developer 사용 가이드

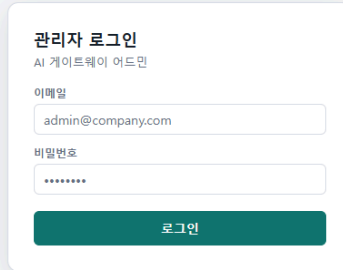
본 가이드는 AI Proxy Gateway에 접근하는 **Developer (개발자)** 역할의 사용자가 포털 웹 콘솔을 활용하고, 본인의 API Key를 스스로 발급 및 관리(수명주기 제어)하며, 로컬 개발 도구(IDE)에 연동하는 모든 과정을 실제 서비스 구동 화면 스크린샷과 함께 상세히 설명합니다.

💡 안내 (Notice)

AI Proxy Gateway의 일부 고급 기능과 화면 레이아웃은 최적의 성능 제어 및 기능 확장을 위해 **지속적으로 개발 및 개선** 중에 있습니다. 이에 따라 실제 콘솔의 특정 UI나 작동 방식이 본 가이드의 내용과 미세하게 다를 수 있음을 사전에 안내해 드립니다.

1. 안전한 포털 로그인 (Secure Portal Login)

AI Proxy Gateway는 강력한 역할 기반 접근 통제(RBAC)를 탑재하고 있어, 개발자가 웹 포털 및 API 기능을 사용하기 위해선 본인 인증을 먼저 거쳐야 합니다.



The image shows a login form titled '관리자 로그인' (Admin Login) for the 'AI 게이트웨이 어드민' (AI Gateway Admin). It contains two input fields: '이메일' (Email) with the value 'admin@company.com' and '비밀번호' (Password) with masked characters '*****'. A green '로그인' (Login) button is at the bottom.

그림 1: AI Proxy Gateway 로그인 화면

1.1 로그인 방식 및 단계

1. 이메일 및 패스워드 인증:

- 활성화된 본인의 개발자 계정 이메일(예: `your-email@company.com`)과 사전에 안전하게 발급받은 개인 비밀번호(보안을 위해 비공개)를 입력창에 각각 타이핑합니다.
- 우측 하단의 **[로그인]** 버튼을 클릭하여 인증을 마칩니다.

2. SSO (Single Sign-On) 로그인 연동:

- 사내 OIDC 연동(Keycloak 등)이 활성화되어 있을 경우, 화면 하단에 **"SSO 로그인"** 버튼이 함께 제공됩니다. 이를 활용하면 사내 통합 계정을 이용해 비밀번호 입력 없이 한 번에 로그인이 가능합니다.

사내 보안 권장 사항

보안성 극대화 및 사내 통합 자격증명 수명주기 통제를 위해, 포털 로그인 시 가급적 ****사내 연동된 SSO Keycloak 로그인 인증 방식****을 활용하여 접근할 것을 강력히 권장합니다. 로컬 직접 계정 로그인은 인프라 장애 등의 비상시에 대비한 대체 통로입니다.

NOTE

최초 로그인 성공 시, 계정에 기본적으로 `developer` 역할이 부여되며 개인 맞춤화 대시보드로 자동 연결됩니다.

2. 내 홈: 개인화 대시보드 (My AI Home)

로그인이 성공하면 개발자 전용 맞춤형 랜딩 화면인 "내 홈 (My AI Home)"으로 이동합니다. 개발 업무를 둘러싼 통계, 비용, 보안 정책 차단 이력, 사용 가능한 AI 자산들이 단일 화면에 유기적으로 시각화되어 제공됩니다.

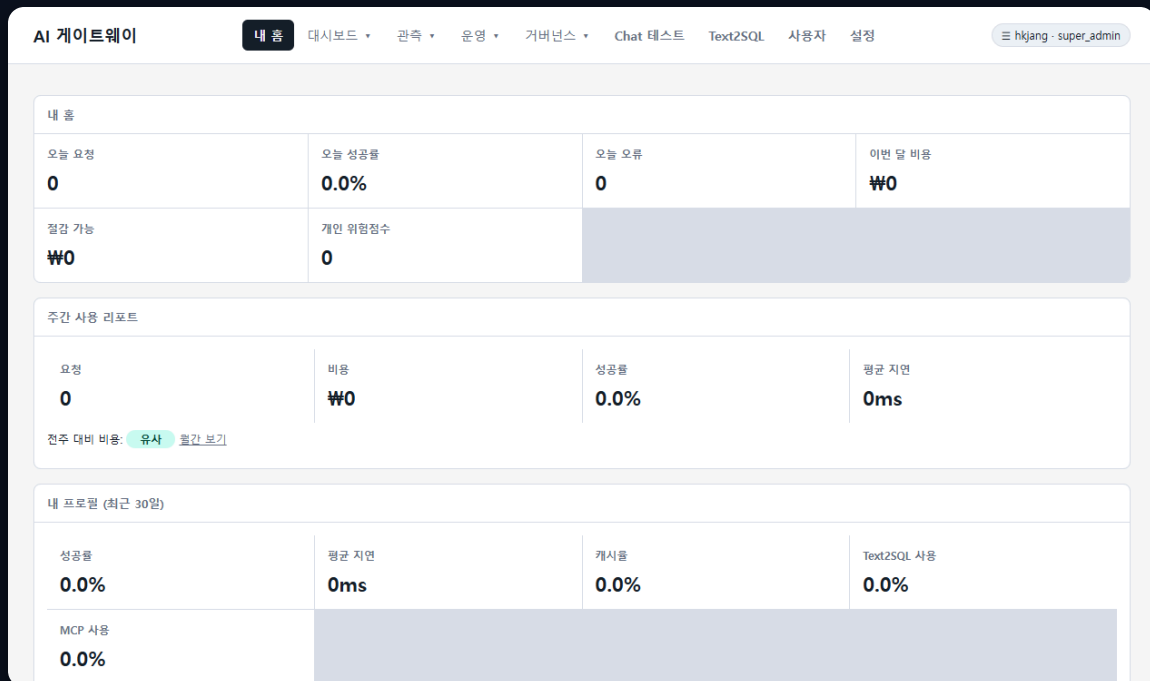


그림 2: 개발자 개인화 랜딩 - 내 홈 (My AI Home)

2.1 핵심 구성 요소 및 기능 명세

- **오늘 사용량 KPIs:** 오늘 하루 동안 누적된 요청수, 오류수, 평균 성공률을 실시간 제공하며, 이번 달 누적 원화 비용과 라우팅 보정을 통해 아낀 절감 가능 비용을 실시간 계량화하여 보여줍니다.

- **내 프로필 (최근 30일):** 나의 평균적인 호출 성공률, 평균 응답 지연 시간(ms), 캐시 적중률(%), Text2SQL 및 MCP 사용 빈도를 분석하고 자연어로 요약 보고합니다.
- **내 사용 패턴 & 자주 쓰는 모델:** 내 코딩 트래픽을 분류하여 탑 작업 유형(예: Refactor, Debug 등) 및 많이 쓰는 MCP 도구 통계를 제공하고, 모델별 호출수와 비용을 테이블로 깔끔하게 정리해 줍니다.
- **최근 차단 사유 (Security Firewall):** 작업 도중 실수로 Secret(비밀번호, API 키 등)을 코드에 임베딩했거나 위험 구문으로 인해 게이트웨이 보안 방화벽에 걸린 경우, "**매칭된 보안 규칙**"과 "**상세 차단 사유**"를 인라인으로 투명하게 노출하여 자가 수정을 유도합니다.
- **내 업무 추천 모델:** 최근 작업 통계를 기반으로 개별 추천하는 모델(👍) 및 지양하는 모델(⚠️) 정보를 인라인 배지로 안내하며, 팀 전체 멀티모델 평가에서 가장 점수가 높았던 "**팀 우승 모델(🏆)**" 리더보드를 함께 띄워 선택을 돕습니다.
- **내가 사용 가능한 Skill:** 사내에 배포된 공인 AI 프롬프트 지침서(Skill)의 카탈로그입니다. 사용 후 평점 피드백을 주거나, 접근 권한이 없는 스킬에 대해서는 [**접근 요청**] 결재를 올릴 수 있습니다.
- **최근 요청 / 영수증 (Request Receipt):** 내가 호출한 API 상세 내역을 나열하고, [**영수증 보기**] 버튼을 클릭하면 토큰 상세량(Prompt/Completion/Cached), 지연, 원화 비용 외에도 **어떤 이유와 판단으로 해당 LLM 모델이 선택되어 라우팅되었는지(라우팅 이유)** 세부 인과관계를 명세합니다.

3. 내 키 발급 및 수명주기 관리 (API Key Self-Service)

개발자가 로컬 IDE(Cursor, VS Code 등)나 파이썬 스크립트에서 AI Gateway를 연동하려면, 전용 **Proxy API Key**가 필수적입니다. 본 포털은 관리자 승인 대기 없이 스스로 키를 통제할 수 있는 셀프서비스 패널을 지원합니다.

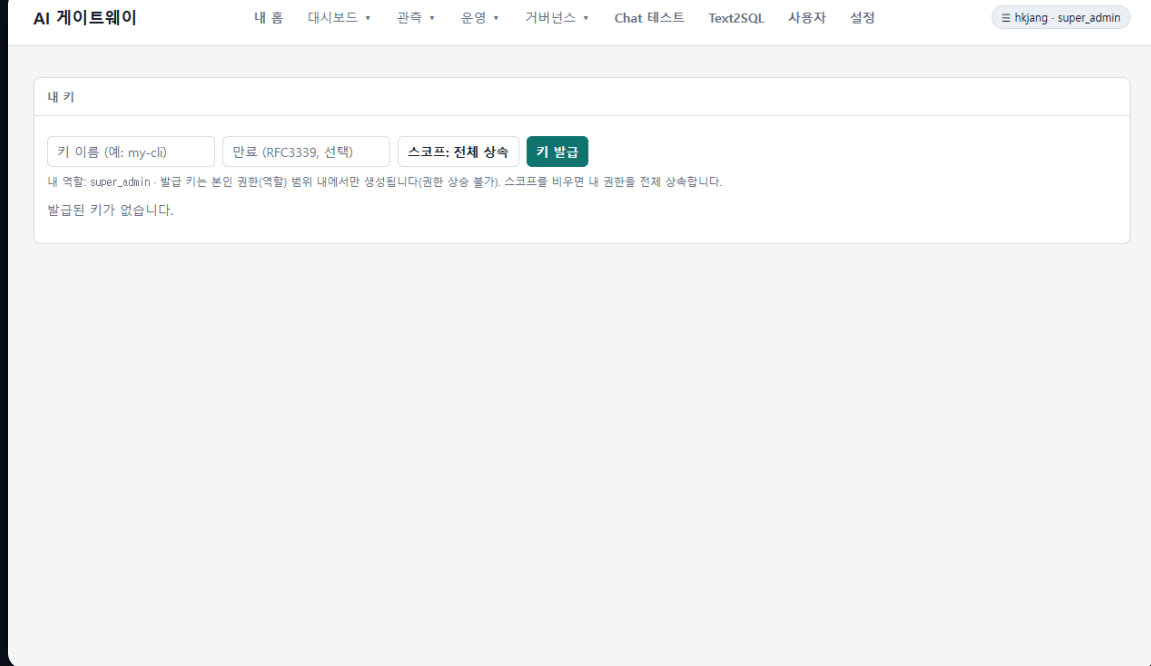


그림 3: 개발자 API Key 셀프서비스 패널

3.1 API Key 수명주기 제어 단계

1. 신규 발급 (Create):

- 우측 상단 **[새 키 발급]** 버튼을 누릅니다.
- 키 이름(예: `cursor-macbook-key`)을 입력하고, 필요한 scope(`self`, `mcp:use` 등)를 선택한 뒤 발급을 완료합니다.
- 주의: 발급된 비밀 시크릿 값(Secret)은 **최초 1회만 화면에 표시**되며 담은 후엔 다시 볼 수 없으므로, 즉시 복사하여 사내 안전한 비밀 저장소에 관리하십시오.

2. 스코프 조율 (Scope Edit):

- 보안 상황이나 사용 용도에 따라 키의 권한을 축소/확장하고 싶을 때, 목록의 **[스코프]** 버튼을 눌러 체크박스로 실시간 조율 및 저장할 수 있습니다.

3. 키 회전 (Rotate):

- 사용 중인 키의 유출이 우려되거나 만료 임박 시, **[회전]** 버튼을 클릭합니다.
- 기존 키와 동일한 권한을 가진 **신규 키**가 즉시 발급(시크릿 1회 노출)되며, 기존 키는 **12시간의 임시 유효기간(Grace Period)** 동안 여전히 유효하게 작동하다가 자동 폐기됩니다. 이 유효기간 덕분에 개발자는 로컬 개발 환경의 환경설정을 중단 없이 안전하게 신규 키로 교체할 수 있습니다.

4. 즉시 폐기 (Revoke):

- 키를 분실했거나 프로젝트가 만료된 경우 **[폐기]** 버튼을 누르면, 해당 키는 즉각 무효화 처리되어 영구적으로 차단됩니다.

⚠ WARNING

모든 API Key는 **개발자 본인 계정의 통합 사용량 예산 한도(Quota)**를 공유하여 차감되므로, 다수의 키를 발급하더라도 통합 한도 내에서 안전하게 비용이 제어됩니다.

4. 핵심 API 호출 가이드 (OpenAI Compatible API)

AI Proxy Gateway는 업계 글로벌 표준 규격인 **OpenAI Compatible API** 인터페이스 규격을 완벽하게 내장하고 있습니다. 개발자는 별도의 라이브러리 추가 없이 기존에 사용하던 OpenAI SDK나 표준 Curl 클라이언트를 수정 없이 그대로 사용하여 게이트웨이를 구동할 수 있습니다.

4.1 Curl을 활용한 Chat Completion API 호출 예시

터미널 및 스크립팅 환경에서 직사하는 표준 호출 방식입니다. **Authorization** 헤더에 발급받은 Proxy API Key를 싣고 **vibe/auto** (지능형 라우팅) 모델을 지정해 호출합니다.

```
curl https://{gateway-url}/v1/chat/completions \
  -H "Content-Type: application/json" \
  -H "Authorization: Bearer <YOUR_API_KEY>" \
  -d '{
    "model": "vibe/auto",
    "messages": [
      {"role": "user", "content": "AI Proxy Gateway의 핵심 기능 3가지를"}
    ],
    "temperature": 0.7
  }'
```

4.2 Python OpenAI SDK 연동 예시

공식 `openai` SDK를 완벽히 재 활용하며, `base_url` 및 `api_key` 두 값만 게이트웨이 정보로 오버라이드하여 연동을 완수합니다.

```
from openai import OpenAI

# AI Gateway 주소 및 발급 키 연동
client = OpenAI(
    base_url="https://{gateway-url}/v1",
    api_key "<YOUR_API_KEY>"
)

# vibe/auto를 지정해 지능형 최적 라우팅 수행
response = client.chat.completions.create(
    model="vibe/auto",
    messages=[
        {"role": "user", "content": "안녕하세요! 코드 분석 도구를 기동해"},
    ],
    temperature=0.2
)

print(response.choices[0].message.content)
```

5. 로컬 환경 및 개발 도구 연동 (IDE & MCP Integration)

AI Proxy Gateway는 터미널 및 외부 IDE 에이전트가 Gateway의 고유 기능들을 도구로 호출할 수 있게 해주는 자체 **MCP(Model Context Protocol) Server** 규격을 내장하고 있습니다.

5.1 Cursor / Claude Desktop / Roo Code 연동 설정

'내 홈'의 하단 "내 개발도구 연결하기 (MCP)" 카드에서 설정을 복사해 로컬 IDE 환경에 연동합니다.

```
{
  "mcpServers": {
    "vibe-gateway": {
      "url": "https://{gateway-url}/mcp/gateway",
      "headers": {
        "Authorization": "Bearer <YOUR_API_KEY>"
      }
    }
  }
}
```

- 위의 `<YOUR_API_KEY>` 부분에 이전 단계에서 발급받은 본인의 **Proxy API Key**를 삽입하면 즉시 연동이 마무리됩니다.
- 연동 시 로컬 AI 에이전트가 `gateway_list_models`, `gateway_estimate_cost`, `gateway_check_quota`, `gateway_route_preview` 등의 7대 자체 지능 도구를 직접 구동할 수 있어, 코딩 도중 언제든지 예산이나 최적 모델 조회를 협업 툴로 수행할 수 있습니다.

5.2 연결 진단기 (Connection Doctor)

만약 로컬 클라이언트에서 연동이 원활하게 작동하지 않을 때, 포털의 "연결 진단" 기능을 활용하십시오. 대상 클라이언트(OpenAI SDK, Cursor, Roo Code, Claude Desktop 등)를 선택하고 [연결 진단] 버튼을 클릭하면, 서버가 즉시 인프로세스(in-process) 가상 통신을 흘려보내 **인증, 스코프 매핑, 모델 권한, Quota 한도, endpoint 도달성, MCP initialize 프로토콜**을 항목별로 1초 만에 자가 검증하고, 문제가 식별될 경우 즉시 구체적인 [조치 가이드]를 화면에 제공해 줍니다.